Android APK 资源分析之 Python 实现

作者

马彦彦 京东零售-技术与数据中台-共享技术部-移动技术组 软件开发工程师岗

1. 背景

随着业务的快速迭代增长,京东主站 APP 不断加入新的代码、图片资源、第三方 SDK、React Native 等等,直接导致 APK 体积不断增加。APK 体积增长也会带来诸多问题,例如:推广费用增加,用户下载意愿降低,流量费用增加,下载及安装成功率降低,甚至可能会影响用户留存率;应用市场限制,Google Play 规定安装包上限为 100M。所以 APK 瘦身已经是迫在眉睫的事情。在尝试瘦身过程中,我们借鉴了很多业界其他同行的方案,比如资源混淆、图片压缩/转码等,同时针对自己需求发现了一些新的技巧。本文主要讲解如何使用 Python 对 APK 进行分析,统计基础数据,分析可优化的资源,为应用瘦身提供数据支持。

分析 APK 的前提条件就是要充分了解 APK 组成,所以下文将首先简单介绍 APK 组成。

2. APK 文件目录

APK 是一个压缩包,使用 aapt l file.apk 命令可以查看 APK 下所有文件,如下:

```
lynnma@lynnma-Vostro-3668:~/software/android/Sdk/build-tools/23.0.2$ aapt l /hom
e/lynnma/Desktop/JDMALL-V8.3.4.apk
classes6.dex
builddef.lst
classes.dex
com/sina/weibo/sdk/net/cacert cn.cer
com/jingdong/common/readme.md
com/jingdong/common/utils/PersonalDesCommonUtils.kt
classes3.dex
classes4.dex
AndroidManifest.xml
lib/armeabi-v7a/libcom.jd.lib.jdpaycommon.so
lib/armeabi-v7a/libyoga.so
lib/armeabi-v7a/libjdface.so
lib/armeabi-v7a/libSecurity.so
lib/armeabi-v7a/libphccommon-lib.so
lib/armeabi-v7a/libmlsdkhelper.so
```

简单归类如下:

文件目录	描述	
lib/	存放so文件,可能会有armeabi,armeabi-v7a,arm64-v8a,x86,x86_64,mips,大多数情况下只需要支持armeabi与x86的框架即可,如果非必须可以考虑只保留armeabi	
res/	存放编译后的资源文件,例如:drawable,layout,anim等等	
assets/	应用程序的资源, res资源会映射到R. txt文件中, 每一个资源都有属于自己独一无二的ID, 而assets文件可以直接通过访问文件地址来使用AssetManager进行访问	
META-INF/	该文件夹一般存放已经签名信息,用来保证apk包的完整性和系统安全. 没有签名的app是不被系统认可且无法安装到手机中	
classes(n).dex	classes文件是Java编译后的生成的字节码文件	
resources.arsc	编译后二进制资源文件索引,记录了资源文件(res目录中文件)和资源文件ID的映射关系,保序运行时可以根据资源ID获取到形影的资源	
AndroidManifest.xml	Android应用的配置清单文件,它描述了每个应用的name,version,permission,以及Android四大组件注册等内容	

当然还会有一些其他文件,例如 org/, src/, aidl 等等文件或文件夹, 这些资源是 Java Resources, 具体详情可以了解下 APK 打包流程。

在充分了解 APK 组成部分后,下面来介绍下 APK 扫描实现主要工作

3. APK 分析主要工作

分析 APK 主要分为以下部分:

- 1. 下载 APK 以及 mapping 文件
- 2. AAPT 获取 APK 信息
- 3. 读取 APK 在操作系统中大小(apk file size)以及 APK 真正大小(apk download size)
- 4. 还原混淆后资源 ID
- 5. 根据文件 MD5 判断重复资源文件
- 6. 读取 DEX 头文件获取 classes.dex 的 class numbers 和 references methods
- 7. 获取非 alpha 通道图以及图片尺寸,遍历出非透明通道图
- 8. ZipFile 解压 APK 的 so 文件并读取 so 文件内容,还原 so 混淆的资源 ID, so 中非透明通道图
- 9. res/下无用资源

以上工作主要使用 Python 进行实现, Python 断点续传下载 APK 以及 Mapping 文件之后解 压文件,为之后分析 APK 做好准备。这里关于 Python 下载实现不再赘述。

3.1. AAPT 获取 APK 信息

通过 AAPT 命令可以获取 APK 的 package_name, version_name, version_code, launch_activity, min_sdk_version, target_sdk_version, application_label 等信息

具体实现如下

```
def get_apk_base_info(self):

# 获取 apk 包的基本信息

p = subprocess.Popen(self.aapt_path + " dump badging %s" % self.apkPath, stdout=subprocess.PIPE,

stderr=subprocess.PIPE,

stdin=subprocess.PIPE, shell=True)

(output, err) = p.communicate()

package_match = re.compile("package: name='(\S+)' versionCode='(\d+)'

versionName='(\S+)'").match(output.decode())

if not package_match:
```

```
package name = package match.group(1)
version code = package match.group(2)
version_name = package_match.group(3)
launch activity match = re.compile("launchable-activity: name='(\S+)'").search(output.decode())
if not launch_activity_match:
  raise Exception("can't get launch activity")
launch_activity = launch_activity_match.group(1)
sdk version match = re.compile("sdkVersion:'(\S+)").search(output.decode())
if not sdk version match:
min_sdk_version = sdk_version_match.group(1)
target_sdk_version_match = re.compile("targetSdkVersion:'(\S+)'").search(output.decode())
if not target sdk version match:
  raise Exception("can't get target sdk version")
target_sdk_version = target_sdk_version_match.group(1)
application\_label\_match = re.compile("application-label:'((\u4e00-\u9fa5\_a-zA-Z0-9-\S]+)').search(output.decode i))
if not application_label_match:
  raise Exception("can't get application label")
application label = application label match.group(1)
return package name, version name, version code, launch activity, min sdk version, target sdk version, application label
```

3.2. apk_file_size & apk_download_size

apk_file_size 是 APK 在操作系统中占据存储空间,可以通过 os 模块直接获取; apk_download_size 是 APK 内实际大小,可以 ZipFile 获取每个文件压缩大小,实现如下:

```
def get_apk_size(self):
    # 得到 apk 的文件大小
    size = round(os.path.getsize(self.apkPath) / (1024 * 1000), 2)
# return str(size) + "M"
return os.path.getsize(self.apkPath)

def get_apk_download_size(apk_file_name):
# 获取 apk_download_size

zip_file = zipfile.ZipFile(apk_file_name, 'r')

zip_infos = zip_file.infolist()

download_size = 0

for index in range(len(zip_infos)):
    zip_info = zip_infos[index]
    download_size += zip_info.compress_size
    return download_size
```

3.3. ZipFile 读取 APK 文件

许多人多使用 apktool.jar 解压 APK,然后遍历 APK 文件夹,该方法可以解决除 apk_download_size 大部分功能,介于以上获取 apk_download_size 使用 ZipFile 读取 APK

文件,这里同样采用 ZipFile 读取 APK 内容。且将 APK 文件作为压缩文件直接使用 ZipFile 进行读取压缩文件内容,该方法可以免去解压 APK 流程,一定程度上提高遍历速度。

```
def get files from apk(apk file name, apk name without suffix, mapping name without suffix):
  proguard map = reproguard.read proguard apk(mapping name without suffix)
  zip_file = zipfile.ZipFile(apk_file_name, 'r')
  file name list = zip file.namelist()
  for index in range(len(file name list)):
    file_name = str(file_name_list[index])
    if proguard_map:
       entry name = str(reproguard.replace path id(file name, proguard map)) if("/" in file name) else file name
       entry_name = file_name
    md5_str = md5.get_md5_value(file_name)
     parent dir = entry name[:parent index] if parent index >= 0 else ""
    zip info = zip file.getinfo(file name)
     file_info = FileInfo(
            =file name,
                   =entry_name,
               =md5_str,
                      =zip info.compress size,
                =file_type,
              =zip info
    if "so" == file type and "libcom.jd.lib" in entry name:
        elif "assets/jdreact/" in entry_name:
    elif "dex" == file_type:
    elif file_util.is_image(entry_name):
    zip file.close()
  return apk_file_list, aura_bundles, dex_files, react_modules
```

3.4. 解析 DEX 文件

以上内容可以获取 APK 中大部分内容,但是要获取 APK 中涉及的 class 数目,以及 methods 数目,显然以上分析均不能满足条件。这也是需要了解 DEX 结构并分析 DEX 文件的原因所在。DEX 文件作为 Android APK 的组成部分,是 Android 的 Java 代码经过编译生成 class 文件,在经过 dx 命令生成的,它包含了 APK 的源码,反编译时最主要就是 对这个文件进行反编译。首先简单了解下 DEX 文件格式。

DEX 格式

名称	格式	说明
header	header_item	DEX 文件头部,记录整个 DEX 文件的相关属性
string_ids	string_id_item[]	字符串数据索引.记录了每个字符串在数据区的偏移量
type_ids	type_id_item[]	类型数据索引.是 DEX 文件引用的所有类型(类,数组或原始类型)的字符串索引
proto_ids	proto_id_item[]	方法原型索引.记录了方法声明的字符串(指向 string_ids),返回类型(指向 type_ids),参数列表(指向 typeList)
field_ids	field_id_item[]	字段数据索引.是 DEX 文件引用的所有字段索引,记录了所属类,字段类型(指向 type_ids)和字段名(指向 string_ids)
method_ids	method_id_item[]	方法索引.记录了所属类名,定义类型(指向 type_ids),方法名称(指向 string_ids),方法原型(指向 proto_ids)
class_defs	class_def_item[]	类定义数据索引,记录了指定类各类信息,包括8各部分,类的类型,访问标志,父类类型,实现接口,源文件,注解,class_data
method_handles	method_handle_item[]	方法句柄列表
data	ubyte[]	数据区,上面所有表格的支持数据
link_data	ubyte[]	静态链接文件中使用数据

从 DEX 文件格式中我们看到有 string、field、class、method 等标识符列表,唯独没有我们想要了解的 class、methods、field、string 数量及其所在偏移量。这时我们看到一个 header 组成部分,经了解 header 组成如下:

字段名称	偏移值	长度	说明
magic	0x0	8	魔数字段,值为"DEX\n035\0"
checksum	0x8	4	校验码
signature	0xc	20	sha-1 签名
file_size	0x20	4	DEX 文件总长度
header_size	0x24	4	文件头长度,009 版本=0x5c,035 版本=0x70
endian_tag	0x28	4	标示字节顺序的常量
link_size	0x2c	4	链接段的大小,如果为0就是静态链接
link_off	0x30	4	链接段的开始位置
map_off	0x34	4	map 数据基址
string_ids_size	0x38	4	字符串列表中字符串个数
string_ids_off	0x3c	4	字符串列表基址
type_ids_size	0x40	4	类列表里的类型个数
type_ids_off	0x44	4	类列表基址
proto_ids_size	0x48	4	原型列表里面的原型个数

proto_ids_off	0x4c	4	原型列表基址
field_ids_size	0x50	4	字段个数
field_ids_off	0x54	4	字段列表基址
method_ids_size	0x58	4	方法个数
method_ids_off	0x5c	4	方法列表基址
class_defs_size	0x60	4	类定义标中类的个数
class_defs_off	0x64	4	类定义列表基址
data_size	0x68	4	数据段的大小,必须 4k 对齐
data_off	0x6c	4	数据段基址

其中有 method_ids_size 和 class_defs_size, 这两个数据就是所需要得到 class 数量和 references methods 数量,另外还有一些其他 string_ids 数目以及偏移量,type_ids 数量以及偏移量等等。

所以读取 DEX header 即可得到 DEX 中定义的 class 方法数以及引用方法数。Android 虚拟机也是通过引用方法数(references methods)进行分包。

references methods 包括第三方引用方法+自定义方法数。可以作为分析 DEX 的标准,具体实现如下:

```
method ids off = struct.unpack('<L', m[0x5C:0x60])[0]
class defs size = struct.unpack('<L', m[0x60:0x64])[0]
class_defs_off = struct.unpack('<L', m[0x64:0x68])[0]</pre>
data size = struct.unpack('<L', m[0x68:0x6C])[0]
data off = struct.unpack(<L', m[0x6C:0x70])[0]
header data = dict({})
header_data['string ids size'] = string_ids_size
header data['string ids off'] = string ids off
header_data['type_ids_size'] = type_ids_size
header_data['type ids off'] = type_ids_off
header_data['proto ids size'] = proto_ids_size
header_data['proto ids off'] = proto_ids_off
header data['field ids size'] = field ids size
header_data['field_ids_off'] = field_ids_off
header data['method ids size'] = method ids size
header_data['method ids off'] = method_ids_off
header data['class defs size'] = class defs size
header_data['class_defs_off'] = class_defs_off
header data['data size'] = data size
header data['data off'] = data off
self.header = header data
```

3.5. 获取非 alpha 通道图以及图片尺寸

在计算机图形学中,每一张图片都是由一个或多个数据通道构成。例如:RGB 图像就是有3 个通道构成,分别为 R、G、B。而透明通道在一定程度上增强视觉感染力。本文的非alpha 通道图是图片大小>10kb & 非.9.png&没有 alpha 通道的 PNG 图。该过程可以在一定程度上避免使用大图

```
non_alpha = True

except OSError:

pass

finally:

file_info.image_size = image_size

file_info.non_alpha = non_alpha

apk_file_list.append(file_info)

continue
```

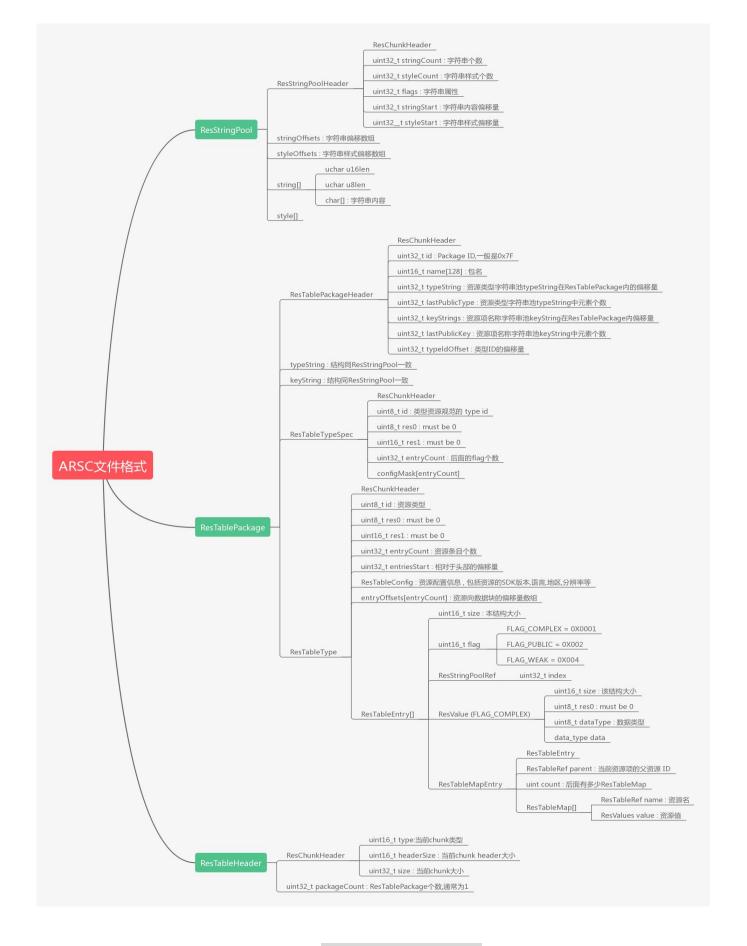
其中 img.size 和 img.mode 是核心代码,可以获取图片尺寸和图片模式

3.6. 重复资源

重复资源的获取是通过对比资源文件的 MD5 值,一个 APP 中存在不同名称的图片具有相同的 MD5 值,那么这些图片便重复需要删除只保留一份即可,实现方法不再赘述。

3.7. 无用资源

以上分析可以满足 APP 资源对比,分析资源增减情况需求,更加直观分析 APP 中大小增长过快模块。但在 APK 瘦身中还有一个更行而有效方法——无用资源,无用资源包含 res 目录下资源以及 assets 目录下资源。在分析这两块无用资源的首要工作:了解 AAPT 打包 APK 资源方法。在 AAPT 打包资源文件中,项目中的 AndroidManifest.xml 文件和布局文件 XML 都会被编译,然后生成相应的 R.java,存放在 APP 的 res 目录下的资源在打包前会被编译成二进制文件,并且为每一个该类文件赋予一个 resource id。对于该类资源的访问,应用层则是通过 resource id 进行访问。Android 应用在编译过程中 AAPT 工具会对资源文件进行编译,并生成一个 resource.arsc 文件,而 resource.arsc 文件其实就是一个文件索引表,所有 res 目录下资源都会在这个文件中,所以分析 res/无用资源首要就是要简单了解下 resources.arsc 文件。



在我们使用 apktool 进行反编译后,res/values/public.xml 就是分析 resources.arsc 而来的。 了解 resource.arsc 文件,可以编写 Python 代码进行分析,获取对应 resource 文件。当然使用 apktool 亦可反编译出相同文件。

3.7.1. res 目录无用资源

AAPT 将 res/目录下资源文件经过混淆直接保存至 r 目录下,且 res 资源可以被 values 目录下 xml、非 values 目录下 xml、AndroidManifest.xml、java 代码中被引用,所以要分析该目录下的无用资源,需要步骤如下:

- 1. 解析 R.txt, 并将 R.txt 中 resources ids 作为全部资源 set<resource id> unusedset 列表中
- 2. 分析 resources.arsc 文件,得到被引用资源文件列表

该部分可以分为 2 部分: values 资源扫描; 非 values 资源(像 layout、animation、drawable 等目录下 xml 文件)扫描。这是因为 values 资源可以引用图片资源,而非 values 资源不仅可以引用图片资源且可以被引用

- 1. values 文件夹下文件直接引用资源列表+manifest.xml 文件中引用资源列表,均放入 set<resource_id>value_references_set 列表中
- 2. 非 values 文件夹,且是 xml 文件中引用资源列表,放入 map<resource_id,set<resource_id>> non_values_references_map
- 3. 分析 DEX 转码为 smali 代码中直接引用的资源,放入 set<resource_id>code_ref_set 列表中
- 4. 将以上所有 set 中数据合并至一个 set 中 references_ref_set 列表中
- 5. unusedset 删除 references_ref_set 中数据
- 6. unusedset 删除 shared_res_public.xml 中标注的自定义 so 库(即 aura)中引用的资源
- 7. unusedset 删除需要被忽略的数据

以上7个步骤即可得到无用资源列表,当然会涉及到资源文件还原等工作,详情请参照上文。

核心实现代码如下:

def read_resource_txt_file(mapping_name):
 resource_txt_path = mapping_name + "/AndroidJD-Phone/hotfix/R.txt"
 # R.txt 解析结果
 resource_def_map = dict({})

```
unused_res_set = set({})
    r txt file = open(resource txt path, "r")
    line = r_txt_file.readline()
    while line:
      columns = line.split(" ")
      if len(columns)>= 4:
         resource_name = "R."+columns[1]+"."+columns[2]
         if not columns[0].endswith("[]") and columns[3].startswith("0x"):
            if columns[3].startswith("0x01"):
              print("ignore system resource %s", resource_name)
              res_id = __parse_resource_id(columns[3].strip())
              if res id:
                 resource def map[res id] = resource name
                 if not ignore_resource(resource_name):
                   unused_res_set.add(resource_name)
        line = r_txt_file.readline()
  except Exception as e:
    raise Exception(resource_txt_path+" file Error,", e)
    return resource def map, styleable map, unused res set
def read_smali_files(smali_path, resource_def_map, styleable_map, r_class_proguard_map):
 resource def set = set({})
    if file_util.is_readable(smali_path):
       smali_file = open(smali_path, "r")
    smali_line = smali_file.readline().strip()
    while small line:
      line = smali line.lstrip('\t')
      if line and line.strip().startswith("const"):
          columns = line.split(",")
          if len(columns) == 2:
                  res id = parse resource id(columns[1].strip())
                  if res id and (res id in resource def map.keys()):
                          resource_def_set.add(resource_def_map[res_id])
   smali line: = smali file.readline()
    raise Exception("read smali files Error,", e)
 return resource def set
def decode_resources(apk_path_dir, res_guard_map):
```

```
non value reference_map = dict({})
resource res used set = set({})
if not apk path dir.endswith("/"):
  apk_path_dir += "/"
res dir = apk path dir+"res/"
if not os.path.exists(res_dir):
  res dir = apk path dir + 'r/'
for paths, sub paths, files in os.walk(res dir):
  path dirs = paths.split("/")
  resource dir = path dirs[len(path dirs)-1]
  res_type = str(resource_dir).split('-')[0]
  if res_type and "values" in res_type:
     for file in files:
       value references set = xml decoder(os.path.join(paths, file), res guard map)
       for resource in value_references_set:
          resource_res_used_set.add(resource)
  elif res_type:
     for file in files:
       if file util.is legal file(os.path.join(paths, file)) and file.endswith(".xml") \
            and not ignore resource(os.path.join(paths, file)):
          res used set = xml decoder(os.path.join(paths, file), res guard map)
          resource = "R." + str(res_type) + "." + file[:file.rfind(".")]
          if resource in res guard map.keys():
            before_resource = res_guard_map[resource].split("R."+res_type+".")[1].replace('.', '_')
            res_guard_resource = "R."+res_type+"." + before_resource
            resource = res guard resource
          if resource in non_value_reference_map.keys():
            reference set = non value reference map.get(resource)
            for item in res used set:
               reference_set.add(item)
            non_value_reference_map[resource] = reference_set
            non value reference map[resource] = res used set
manifest_path = apk_path_dir + "AndroidManifest.xml"
if not file util.is legal file(manifest path):
  logging.warning("File %s is illegal!" % manifest_path)
manifest_ref_set = xml_decoder(manifest_path, res_guard_map)
for reference in manifest ref set:
  resource res used set.add(reference)
return resource_res_used_set, non_value_reference_map
```

3.7.2. assets 目录无用资源分析

经过分析 AAPT 打包 APK 流程可知,assets/下文件直接被保留至 APK 中,所以 DEX 可以直接使用名称进行访问

assets/目录下无用资源分析流程:

- 1. 查找 assets 目录下所有文件,并将文件路径保存至 set<asset_id> assets_path_set 中
- 2. 遍历 smali 代码,查找代码中引用的 assets 资源,并将查找结果放入 set<asset_id>asset_ref_set 中
- 3. assets_path_set 去除 asset_ref_set 剩余的资源,都是未被使用的

核心代码:

```
def find asset file(asset dir):
  if asset dir and os.path.exists(asset dir) and os.path.isdir(asset dir):
     for paths, sub paths, files in os.walk(asset dir):
       for file in files:
          asset file sub dir = paths.split(asset dir)[1]
          unused asset set.add(os.path.join(asset file sub dir, file))
def read_smali_files(smali_path):
  if file util.is readable(smali path):
     smali file = open(smali path, "r")
     smali line = smali file.readline()
      hile smali_line:
       line = smali_line.strip()
       if line and line.startswith("const"):
       elif line.startswith("sget"):
       elif line.startswith("const-string"):
          columns = line.split(",")
          if len(columns) == 2:
             asset_file_name = columns[1].strip()
            if asset file name:
               for path in unused res set:
                  if path.endswith(asset file name):
                    unused res set.remove(path)
        smali_line = smali_file.readline()
```

注意:无用资源分析, 只会分析 Java 代码中使用的资源, 像 React Native 代码中引用资源将不会被扫

描到, 后期如果允许在对相关部分进行研究

4. 结语

使用 Python 我们快速实现了 Android APK 的资源分析,为应用瘦身提供准确的数据 支持,同时也开发了图片压缩、资源混淆、资源托管线上等工具。目前分析平台已搭建完成并进入内测阶段,期望更高效地为应用瘦身提供支持,让 APK 体积将到极致,降低应用分发成本,提升转化率及用户体验。